



本科生毕业论文（设计）

题目： 基于远程直接内存访问的
分布式内存对象存储数据传输优化

姓 名	<u>兰 靖</u>
学 号	<u>18340085</u>
院 系	<u>计算机学院</u>
专 业	<u>计算机科学与技术</u>
指导教师	<u>肖依 (教授)</u>

2022 年 4 月 1 日

**基于远程直接内存访问的
分布式内存对象存储数据传输优化**

**Data Transfer Optimization of Distributed
In-Memory Object Store Using RDMA**

姓 名	兰 靖
学 号	18340085
院 系	计算机学院
专 业	计算机科学与技术
指导教师	肖依 (教授)

2022 年 4 月 1 日

学术诚信声明

本人郑重声明：所呈交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文（设计）不包含任何其他个人或集体已经发表或撰写过的作品成果。对本论文（设计）的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本论文（设计）的知识产权归属于培养单位。本人完全意识到本声明的法律结果由本人承担。

作者签名：

日 期： 年 月 日

【摘 要】

随着大数据处理、大规模智能模型训练、强化学习等多样化、高负载的计算需求成为学术界和产业界的焦点,作为计算基础设施的分布式计算框架(例如 Mapreduce, Spark, Ray)正在得到更多的关注和更广泛的应用。通常,计算框架软件负责为用户调度计算任务,同时管理和最大限度地利用计算集群的物理资源。上述场景所产生的快速增长的计算需求,正在使计算集群的性能愈发捉襟见肘:一方面,高性能计算(HPC)集群正在取代廉价的计算机器以应对高强度计算。值得注意的是,前者所拥有的新型高性能网络,明显地区别于传统集群。以智能网卡为硬件基础,高性能计算机能够在无中央处理器(CPU)的介入下,对机器内存直接读写和传输数据。这种被称为远程直接内存访问(RDMA)的传输机制,相比以太网具有低占用、低延迟、高带宽等技术优势。另一方面,作为基础设施的软件框架,也在面临严峻的性能挑战:当前大多数分布式计算框架仍然缺乏对高性能硬件的支持,特别是无法充分利用集群中的高速网络资源。

Ray 作为近年来兴起的分布式计算框架,同样存在着上述性能瓶颈。因此,通过设计恰当的高性能通信机制,我们能将现代网络的硬件优势转化为 Ray 系统整体的性能优势。本研究从该框架的核心组件:分布式内存对象数据库 Plasma 入手,首先测试和分析了其基于以太网和套接字传输数据而导致的性能瓶颈。然后,在高性能集群上,我们提出了一种支持 RDMA 特性的高吞吐数据传输机制。该机制针对大型数据,提出了基于单边读语义的传输协议,实现了用户态的内存零拷贝。并且该机制能够在运行时,根据数据大小动态地选择传输协议,以获得最佳性能。进一步,我们基于并行计算范式 MPI 构造了分布式、可扩展的多节点传输性能测试。在实验中,我们确定了传输协议的最优参数,并且展示了在天河高性能集群上,优化后的内存平台能够在常见大小的对象传输中实现至多 8 倍的吞吐率提升。

关键词: 数据传输, 高性能网络, RDMA, 键值对数据库, 分布式缓存

[ABSTRACT]

Keywords: data transfer, high-performance network, RDMA, key-value database, distributed memory

目录

1	绪论	1
1.1	选题背景与意义	1
1.2	国内外研究现状和相关工作	2
1.3	论文主要研究内容	6
1.4	论文结构与章节安排	7
2	Plasma 分布式内存存储架构和性能分析	8
2.1	Ray 架构简介	8
2.2	Plasma 架构分析	9
2.3	基于套接字的 Plasma 通信机制	11
2.4	Plasma 存储和传输基准测试	12
3	基于 RDMA 的 Plasma 数据传输机制实现	14
3.1	连接的建立和复用	14
3.2	基于双边通信的传输协议	15
3.3	基于单边通信的传输协议	17
3.4	混合传输机制实现	18
4	性能测试与结果分析	20
5	总结与展望	21
	参考文献	22
	附录 A 补充更多细节	23
A.1	补充图	23
	致谢	24

插图目录

1.1	队列对 (QP) 示意图	4
2.1	Ray 计算架构	8
2.2	Plasma 工作机制	9
2.3	Plasma 存储架构	9
2.4	基于套接字的 Plasma 通信机制	12
2.5	Redis 和 Plasma 常见操作吞吐对比	12
2.6	Redis 和 Plasma 数据传输吞吐对比	13
3.1	基于双边通信的传输协议	15
3.2	基于单边通信的传输协议	17
A.1	一个配有彩色表格的插图	23

表格目录

2.1 Plasma 客户端接口	10
2.2 Plasma 集群接口	11

1 绪论

1.1 选题背景与意义

分布式计算框架是一种复杂的平台软件。传统的并行计算范式如信息传递接口 (MPI) 和分区全局地址空间 (PGAS), 通常为编程者提供丰富的调用接口和灵活的编程空间。然而, 使用这些编程标准的门槛过高: 编程者通常需要自己管理多台机器的状态, 特别是内存的分配和使用; 编程者还需要使用给定的标准原语, 精确地规定多个进程之间的通信和协作方式, 这通常需要大量时间和精力; 另外使用这些范式将导致程序和功能的强耦合——编程者很可能不得不重新编写代码来更新程序的逻辑。因此, 现代分布式计算框架通常承担了上述硬件管理的角色, 并针对目标任务类型, 为用户设计尽可能少、但简单易用的功能接口, 来降低集群的使用难度。传统的分布式计算框架, 例如 Mapreduce 和 Spark, 都是面向大规模数据分析而设计的。然而, 近些年以强化学习、复杂工作流等为代表的复杂计算需求, 需要更灵活的框架支持。加州大学伯克利分校 RISELab 实验室提出的 Ray 和芝加哥大学 Globus 实验室提出的 Parsl 是其中两个典型。这些框架吸取了云计算领域“函数即服务 (Function as a Service, FaaS)”的设计思想, 能够细粒度地以函数为单位将任务调度到集群上执行, 同时依然对用户隐藏绝大部分实现细节。Ray 通过分布式内存对象存储 Plasma, 实现了框架完全自主的集群内存管理, 让用户可以专注于实现功能逻辑, 无需担心数据的存放和移动。Ray 在保持易用性的前提下, 极大地提升了计算框架的灵活性, 用户只需要修改几行代码就能将单进程程序扩展到整个集群, 进而实现分布式机器学习等复杂模型。

高性能集群 (或超算集群), 是一种以高端处理器、并行加速卡、高性能网络、大容量存储为核心硬件的计算集群。随着大数据应用的丰富、超大规模人工智能模型的出现, 高性能集群和超级计算机正在变得愈发重要。首先, 高性能计算机拥有普通机器不能比拟的计算能力, 主要表现为高端的多核处理器和并行加速卡。而随着大模型时代的到来, 新应用对集群网络的需求快速提高, 高性能网络所表现出的高带宽、低延迟等特性也逐渐受到了更多的关注。当前, 高性能计算集群普遍使用的是英伟达 Mellanox 子公司的 Infiniband 高速网络。这一网络架构的性能优势, 很大程度上来自于对远程直接内存访问 (RDMA) 机制的支持。而对于传统使用套接字 (Socket) 通信的网络程序, 该架构通过“基于 Infiniband 的互联网协议 (IPoIB)”实现支持。值得注意的是, 这是一种依赖操作系统内核的非原生

支持：已经有多个工作表明，其网络性能和直接使用 RDMA 技术相比具有明显差距。然而，要利用 RDMA，用户必须在应用中实现基于 RDMA 的通信机制，而不能依赖于操作系统内核提供的系统调用。因此，基于 Socket 的网络应用大多不能在高性能集群中直接获得显著的性能提升。分布式计算框架 Ray 并不例外，其分布式内存存储 Plasma 目前仅有对传统 TCP/IP 协议的支持，因而在超算集群上无法发挥出应有的网络性能，进而影响 Ray 运行在超算上的总体性能。

因此，本研究的目的是：我们是否能为分布式内存存储 Plasma，提出并实现一种支持 RDMA 机制的内存通信协议，从而让 Plasma 乃至整个 Ray 框架在现代超算集群上获得更好的性能？从超算研究的趋势来说，应用软件和先进超算硬件之间的隔阂，正在逐渐成为大家关注的热点。随着超级计算机和云计算两个领域的融合，会有越来越多的软件运行在高性能集群中。然而，它们中的大部分还没有针对高性能硬件提供软件支持——通过提供软件对高性能硬件的支持，我们能够将这些应用的运行性能提升到全新的水平。

1.2 国内外研究现状和相关工作

1.2.1 分布式计算框架

分布式计算框架是一种复杂的平台软件。在底层，它通过实现任务调度、并发执行、内存管理等基本组件，向用户透明地提供分布式计算的功能；在应用层，它通过设计和规范一系列接口，帮助用户高效地运行特定任务：例如大数据分析 (Mapreduce、Spark)，分布式机器学习 (Ray) 等等。Ray 是近年来最受关注的分布式计算框架，它以函数为单位调度任务执行，完全自主地管理内存移动，并且支持异步执行。借助这一平台，目前社区人员已经实现了机器学习 (Ray ML)、强化学习 (Ray RLlib)、模型部署 (Ray Serve)、工作流 (Ray Workflows) 等上层应用库供用户使用。同时，用户也可以直接在框架上编写任意程序：使用常见的 Python 语法构建出完全分布式的计算程序，而且不会有任何表达能力上的限制。

代码 1.1 Ray 代码示例

```
import ray
ray.init()

@ray.remote
def f(x):
    return x * x

futures = [f.remote(i) for i in range(4)]
```

```
print(ray.get(futures)) # [0, 1, 4, 9]
```

在上述代码片段中，用户通过修饰符“@ray.remote”将函数定义为远程函数，并在下方执行 4 次。值得注意的是，在 Ray 框架的调度下，这四次调用将会逐一调度到不同的进程上并发执行，因此 Ray 能够透明地为任何函数提供并行计算能力。而分布式内存存储 Plasma，则在系统中持续为并发任务调度所需的数据。在示例代码中，Plasma 将会在集群中查找变量 *i* 的位置，并将其拉取到进程中供任务使用。最后，Ray 原生支持异步执行，任何函数调用都会立刻返回，给予用户一个凭证（future）——用户可以立刻用这一凭证作为参数继续调用其他函数，即使数据的真实值还没有求得。Ray 的执行引擎动态地构建和解决数据依赖，将凭证替换为真实值，然后继续调用依赖它的函数。这一异步特性将使 Ray 充分发挥并发任务的性能。

1.2.2 远程直接内存访问技术（RDMA）

RDMA 全称 Remote Direct Memory Access，即远程直接内存访问，是一种于二十一世纪之后逐渐兴起的新型网络通信技术。其核心思想和直接内存访问（DMA）相似——在早期计算机系统当中，内存读写、移动都需要由中央处理器（CPU）直接操作，从而带来相当的性能开销。而现代计算机系统分离出了内存子系统，将内存相关的负载卸载到子系统的专用硬件上。因此，CPU 只需要在访问开始和结束时同子系统协作，在漫长的访问延迟中可以执行其他计算任务，从而大大提高了计算机的总体性能。RDMA 技术在这一方向上更进一步：支持 RDMA 的现代智能网卡，不仅能从网卡端直接寻址并读写本机内存，还能够和远端的另一个网卡协作，直接读写远端机器的内存空间，从而实现通信。这一过程中 CPU 通常只需极少的介入、甚至完全不需要，因此具有相当明显的技术优势：

- 1) 旁路内核（Kernel-bypass）。基于 TCP/IP 协议的网络通信已经逐渐不能适应现代高并发、重负载的网络应用。基于高速 SSD 的存储系统、基于内存的缓存和（键值对）数据库都需要在短时间内应对大量并发的 I/O 操作请求，工作表明这些应用的性能瓶颈位于 CPU，而不是 I/O 部分。臃肿的网络栈、用户态-内核态的切换、内核态的数据处理和拷贝等等，是影响网络系统性能的根本原因。智能网卡能代替 CPU 执行内存移动，而且 CPU 和网卡的大多数交互都实现在用户态，大大减轻了 CPU 的负担。
- 2) 零拷贝（Zero-copy）。零拷贝是当前操作系统领域的一项热门技术，其思想在于提高内存的共享程度，例如减少进程-进程、用户态-内核态内存拷贝的数

量,从而提高 I/O 的整体性能。在支持 RDMA 的应用中,由于内核旁路,一次内存操作往往能省去:用户缓冲到内核缓冲的拷贝、内核缓冲到硬件(驱动)缓冲的拷贝。数据直接在两端主存之间移动,因此产生可观的性能提升。

- 3) 低延迟、高并发。简化的网络路径、零拷贝等特性大大降低了机器操作远端内存的延迟。在并发应用中,更低的延迟意味着相同时间内更强大的并发处理能力。
- 4) 异步通信。RDMA 是原生异步的通信机制,进程需要主动访问完成队列(CQ)甚至直接检查内存数据,才能得知通信的发生。这一特性让程序的并发潜力大大提升,但于此同时,编程者需要自己设计同步机制来完成通信,同样增加了编程上的难度。

目前, RDMA 技术是智能网卡技术中较为成熟的一种。硬件支持 RDMA 的网卡通常都具有相当惊人的网络带宽以及其他诱人的硬件特性:目前, Mellanox NDR Infiniband 网卡能够支持高达 400Gb/s 的网络带宽;另外, Infiniband 标准实现了链路层的容错机制,这意味着通常意义上的丢包在 IB 网络上并不存在,大大降低了用户设计通信机制的难度。加上近十年来新型硬件的价格逐渐走低,学术界和工业界争相尝试这一新技术,并已经有了相当多优秀的成果。尽管 RDMA 存在着其他实现方式,例如基于以太网的 RoCE,但本研究中的 RDMA 机制在硬件上基于超算集群中广泛使用的 Mellanox Infiniband 架构。

基于 RDMA 机制的网络编程,目前主流的做法是使用 Verbs 操作原语。在 Infiniband 网络架构中,两端以队列对(Queue Pair, QP)图 1.1^①为基本模型进行通信,一次简单的发送-接收可以描述为如下步骤:




图 1.1 队列对 (QP) 示意图

- 1) 两端程序各自创建一个队列对,并借助套接字等基础通信方式,交换队列对的基本信息,建立一对连接。
- 2) Infiniband 通信的基本单位是一个(发送/接收/完成)事务:接收方通过 Verbs 调用将一个构造好的接收事务压入到接收队列(Receive Queue)中
- 3) 之后发送方将一个构造好的发送事务压入到发送队列(Send Queue)中。

^① <http://hjemmesider.diku.dk/~vinter/CC/Infinibandchap42.pdf>

- 4) 此时，硬件将为两端处理这一对事务，将本机内存从发送事务指定的内存地址发送到接收事务指定的远端内存地址。
- 5) 硬件完成一次事务操作后，通常将一个完成队列项（CQE）压入到完成队列（Completion Queue, CQ）中。
- 6) 用户进程可以在任何时刻通过弹出完成队列的头部来确认（发送/接收）事务执行完成，或者得到操作失败的错误代码。

以上流程实现了类似 TCP/UDP 的双边通信语义，不过，两者仍然有着本质的区别：RDMA 通信机制是基于事务模型的；以上操作均在用户态完成，无需任何系统调用；数据从一个进程直接发送到另一个进程。除此之外，RDMA 机制还支持使用读/写（Read/Write）等单边通信语义。在执行这些单边操作时，远端应用不需要事先发送接收事务，也不会通过完成队列得知通信的发生。使用单边操作语义将会进一步降低远端 CPU 的介入和负担，从而支持更高强度的并发操作。不过，使用单边语义通常需要引入额外的同步机制以完成通信。

1.2.3 基于 RDMA 技术的内存系统

近年来，针对 RDMA 机制提供的高带宽、低延迟优势，研究人员在多个方向上尝试将其转变为实际应用上的性能提升。特别是在 RDMA 同时支持双边和单边语义的情况下，如何针对实际应用场景，设计合适的通信和协作机制，一直是这一领域研究的重点。从场景的角度来说，目前的主要研究方向是分布式内存系统和高并发的内存系统。

1.2.3.1 分布式内存系统

Infiniband 网络标准和 RDMA 技术最早应用于高性能计算（HPC）领域。俄亥俄州立大学的^[1]首次将 RDMA 技术应用于优化消息传递接口（MPI）的通信机制，这也是最早的、较为完善的一个 RDMA 协作机制实现。这一设计针对 RDMA 单边操作所产生的协作困难问题，预先建立了固定映射的发送-接收缓冲区对，以及设计了自描述的消息块，深刻影响了后续 RDMA 通信方案的设计。并且在 MPI 多年的演进中，其 RDMA 通信机制也不断有优化方案提出。

然而，从集群内存空间的角度来看，RDMA 技术的逐渐成熟，让研究者看到了颠覆性、普适性优化的可能性：优异的访问带宽和极低的访问延迟，已经极大程度地拉近了机器内存之间的“距离”，使得集群规模的共享内存逐渐成为可能：^[2]发现 IB 网络的通信延迟和 PCIe 总线上的通信延迟处于一个数量级，这说明网络已

经不再是集群通信的性能瓶颈。以 RDMA 为核心，HPC 社区和分布式系统社区均提出了一些分布式共享内存的实现方案，从而以较低的性能代价连接起整个集群的内存空间：前者包括 GasNet，OpenSHMEM 等支持分区全局地址空间（PGAS）计算的中间件；后者以 FaRM，CoRM 等系统为代表。这些研究的共同焦点是分布式的事务机制——除了本地内存的读-写冲突之外，还需要解决远端机器读写和本地访存之间的数据冲突。此外，也有研究避开了细粒度的内存管理，如去中心化、可扩展的分布式页表系统 Infiniswap，就通过粗粒度的内存页交换处理集群中存在的物理内存使用不均的问题。

1.2.3.2 高并发内存系统

在另一个方向上，研究人员希望将 RDMA 低延迟、高并发的特性直接变为应用的性能——内存键值对 (key-value) 数据库是一个合适的领域。Redis, Memcached 等内存数据库通常被用作一种高速缓存，其他机器对数据库的访问也主要以并发读取为主，因此非常适合使用 RDMA 技术进行优化，特别是使用单边读等通信方式优化单机并发能力。不过，基于单边操作的读取机制难以应对高强度并发中的数据冲突问题，需要借助于更好的哈希函数等其他优化手段才能获得较好的优化效果。因此近期的工作更是提出了双边语义和单边语义混合的通信机制，从而在 CPU 负载、并发能力和编程难度上都获得较好的结果。总体来说，在过去的一段时间，针对应用场景不同，研究人员已经提出了众多不同的 RDMA 通信范式。

1.3 论文主要研究内容

作为分布式计算框架 Ray 的核心组件，Plasma 并没有对 RDMA 通信的支持，因而在超算集群中存在性能提升的空间。该组件兼有分布式、高并发两方面的特性：作为集群内存存储，Plasma 需要运行在集群的每个计算节点上，并且期望实现最大的并发传输能力，以支撑 Ray 快速的任务调度。不过，Plasma 并没有实现细粒度的并发机制，而是进一步依靠 Redis 等外部机制实现。这使得我们的研究重点倾向于优化大型数据对象的传输性能。在本文中，我们为 Plasma 提出了一种原生支持 RDMA 技术的通信机制，并且在现代超算集群上验证了其在各个数据大小的传输上都获得了更优的性能。

这一工作存在以下挑战：

- 1) 目前 RDMA 编程仍然是极为“小众”的技术，如何能在有限的资料和现有研究帮助下实现高性能的网络通信机制。

- 2) 如何在尽可能不破坏项目整体结构的情况下，为 Plasma 提供原生 RDMA 通信机制。这要求优化后的程序可以无缝地运行在以太网和 Infiniband 两种网络架构上。
- 3) 针对 Ray 框架中可能出现的大小不一的数据，如何实现该机制使得 Plasma 能够在尽可能多的大小范围内都能获得最优的网络性能。

下面总结了本工作的主要贡献：

- 1) 我们通过实验分析了原 Plasma 实现在超算集群上的存储和网络性能，验证了其无法充分利用 Infiniband 高速网络，从而证明了使用 RDMA 技术优化 Plasma 数据传输的可行性。
- 2) 我们针对小对象数据和分布式训练中常见的大对象数据，分别实现了基于双边和单边通信的传输机制。针对大对象，单边通信将实现用户态的零拷贝特性，从而降低了 CPU 数据拷贝而导致的负载和占用时间。
- 3) 我们基于消息传递接口 MPI 实现了分布式、可扩展的数据传输性能测试，比较了优化实现和原实现在各个数据大小上的性能。并且通过实验，我们确定了机制在选择传输方式时的最佳方案，从而获得了最优的整体性能。

1.4 论文结构与章节安排

本文共分为五章，这些章节的内容安排如下：

第一章：绪论。简述了本文的研究背景和意义，简述了本研究的核心技术背景，并介绍了国内外相关工作和研究现状。

第二章：Plasma 分布式内存存储的架构和性能分析。这一章将简要分析 Plasma 的分布式架构，并且通过性能测试和常见内存存储 Redis 进行对比，分析了 Plasma 在传统网络结构上的性能瓶颈。

第三章：基于 RDMA 技术的混合通信机制实现。这一章将详细介绍基于 RDMA 技术的优化方案，并针对大小数据提出混合通信机制的实现。

第四章：实验和分析。这一章将在天河高性能集群上验证优化方案的性能优化，

第五章：总结和展望。这一章将总结本文的主要结果，并且进一步分析后续的工作方向。

2 Plasma 分布式内存存储架构和性能分析

2.1 Ray 架构简介

图 2.1^① 展示了分布式计算框架 Ray 的整体架构，并展示了分布式内存对象存储 Plasma 在其中的位置和角色：




图 2.1 Ray 计算架构

Ray 架构简介：一个 Ray 集群由主节点（Head Node）和工作节点（Worker Node）构成。主节点上运行驱动（Driver）进程，即编写了 Ray 函数和其他逻辑的 Python 程序；另外，还运行着全局控制存储（Global Control Store, GCS）：该数据库存放着 Ray 集群范围的关键配置信息。此外，所有节点都运行着 Ray 集群的核心中间件：Raylet。Raylet 主要由调度器和对象存储构成——调度器负责将 Driver 进程解析出的任务调度到集群的合适节点中运行；对象存储就是 Plasma 数据库，存放着计算所产生的数据——包括任务运行所依赖的输入数据和所产生的输出数据。

Plasma 工作机制：Plasma 对象存储运行在 Ray 集群的所有节点上。图 2.2^② 展示了 Ray 驱动 Plasma 对象存储的基本机制：当 Ray 任务需要获取一个对象 x 以执行任务时，它将调用“ray.get”方法。如果该对象存放在本节点的 Plasma 存储中，后者将通过进程间通信（IPC）将对象传递给任务进程。否则，它首先需要以下图所示从其他节点拉取数据：

- 1) 当前的 Ray 实现通过“拥有（Ownership）”机制管理对象的存储位置。Plasma 向拥有该数据的进程（Owner）查询数据在集群中的位置。
- 2) Plasma 向该节点的另一个（位于节点 2 的）Plasma 进程发起对象请求。

^① <https://docs.ray.io/en/latest/ray-contribute/whitepaper.html>

^② <https://docs.ray.io/en/latest/ray-contribute/whitepaper.html>

3) Plasma 将数据传输并保存到本地。




图 2.2 Plasma 工作机制

值得注意的是，由于对象存储之间、对象存储和任务进程之间的通信，这一机制存在较大的固定延迟，从而在传输小数据时性能相对不佳。因此，现在的 Ray 实现中仅有大于 100KiB 大小的对象通过 Plasma 对象存储实现集群共享——任务进程将更小的数据直接存放在进程的预留空间内，并将这些数据通过内嵌（inline）在 RPC 调用的参数中实现传递。这一实现策略指引我们在接下来的性能测试和分析中关注 Plasma 在大对象传输中的性能瓶颈。

2.2 Plasma 架构分析

Plasma 分布式存储架构由多个进程组成。通过将控制面、数据面上的任务解耦到不同的进程，我们可以较为方便地对其软件架构进行改进。图 2.3 展示了 Plasma 集群的组织结构。




图 2.3 Plasma 存储架构

2.2.1 Plasma 对象存储架构

对象存储 (Object Store) 是 Plasma 运行的最小单元, 即 Plasma 在任意单节点上运行时, 可以不需要连接到管理进程 (Manager) 和 Redis 数据库。图 2.3 中左下方部分展示了这一架构。对象存储的基本架构遵循客户端-服务端的特征。Store 进程负责直接操作和管理机器内存。当用户 (Client) 进程发起创建对象请求时, 会将关键元数据——即对象编号 (id)、元数据大小、数据大小等通过进程间通信 (IPC) 发送给 Store 进程。值得注意的是, Plasma 使用 Unix 域套接字 (Unix Domain Socket) 作为进程间通信方式, 这一方式允许用户端以类似套接字的方式, 通过操作系统内核与本机内的另一个进程交换数据。

Plasma 利用 MMAP 映射机制对内存对象操作进行了性能优化。当前常见的内存数据库如 Redis, 用户端进程和服务端需要直接交换数据以完成创建、读取等操作。而 Plasma 利用了 MMAP 机制, 使得客户端与服务端能够共享内存空间:

- 1) 创建对象时, 服务端使用 MMAP 映射分配内存空间, 将其与一临时文件映射。
- 2) 服务端通过 IPC, 将上述临时文件的文件描述符 (file descriptor, fd) 传递给用户进程。
- 3) 用户进程使用相同的文件描述符 fd 再次调用 MMAP。

如此, MMAP 向 Store 进程和用户进程返回同一个内存地址, 用户进程能够直接读取、操作数据库中的内存对象。这一架构能够将数据库读取操作的开销优化到 $O(1)$ 时间复杂度, 使 Plasma 针对大型对象仍然具有优秀的吞吐能力。Plasma 在对象存储架构中定义了如下操作原语:

表 2.1 Plasma 客户端接口

接口定义	接口描述
plasma_contain(id)	查询对象是否存在
buf ← plasma_create(id, fields, values)	创建参数/数据为 fields/values 的对象
plasma_seal(id)	封装对象使其对其他进程可见
plasma_release(id)	释放对象, 引用计数减一 (为 0 则删除)
buf ← plasma_get(id, fields)	读取对象
plasma_delete(id)	删除对象
plasma_connect(store_addr, manager_addr)	连接到 Store 和 Manager
plasma_subscribe(id)	等待一个对象在本机被创建

2.2.2 Plasma 集群架构

Plasma 存储将其集群架构单独实现为 Manager 进程，多个进程以及一个 Redis 数据库共同构成其集群架构，图 2.3 中上方展示了将 Plasma 连接成集群的架构。Plasma 在集群架构中定义了如下操作原语：

表 2.2 Plasma 集群接口

接口定义	接口描述
<code>buflist ← plasma_fetch(ids)</code>	将 id 列表中的对象拉取到本地存储

管理者 (Manager) 进程仅处理用户进程发出的一种请求，即输入一个 id 列表，执行一次拉取 (fetch) 操作：

- 1) Manager 对列表中的每个 id，从集群中查找对应数据对象的位置。
- 2) 本地 Manager 与存有这一对象的另一个 Manager 建立连接，拉取数据。
- 3) Manager 和 Store 交互将数据保存到本地——对 Store 进程来说，Manager 只是普通的 Client 进程。

在这一过程中，Plasma 依赖于 Redis 提供的数据库服务。每当 Client 进程创建并封装数据对象时，它将借助 Manager 与 Redis 服务器建立通信，并更新该对象在集群中的分布。因此 Manager 在拉取数据的过程中（上述步骤 2），必须先从 Redis 得到数据分布，才能开始一次数据传输。

2.3 基于套接字的 Plasma 通信机制

Plasma 实现了基于套接字 (Socket) 的数据传输机制。通过访问 Redis 服务器获得对象处在的目标节点后，Manager 会逐一尝试建立套接字连接，并拉取数据。其通信机制如图 2.4 所示：

发起者 (Receiver) 首先将一条类别为 PLASMA_TRANSFER 的消息发送给存有数据对象的 Manager 进程。在得知需要发送的对象 id 后，发送方通过向 Store 调用查询操作获得了数据的缓冲区地址。需要注意的是 Plasma 的读取操作具有常数的时间复杂度，因而会马上返回。发送方 (Sender) 会将查询到的元数据（主要是数据大小）通过 PLASMA_DATA 消息返回给接收方，接收方便会向 Store 创建一个同 id 的对象，获得分配的内存空间。最后双方分别进入发送/接收函数，分批将数据转移到本地缓冲区中。

在 Plasma 实现中，默认一次发送 4kb 大小的数据。




图 2.4 基于套接字的 Plasma 通信机制

2.4 Plasma 存储和传输基准测试

为了分析 Plasma 存储运行在超算上存在的性能瓶颈，得到可能的优化方向，我们在天河高性能集群上对 Redis 和 Plasma 进行了存储和传输数据的性能测试。通信性能测试以 IPoIB 机制运行在两节点的 Mellanox Infiniband 网卡上。

2.4.1 存储性能测试

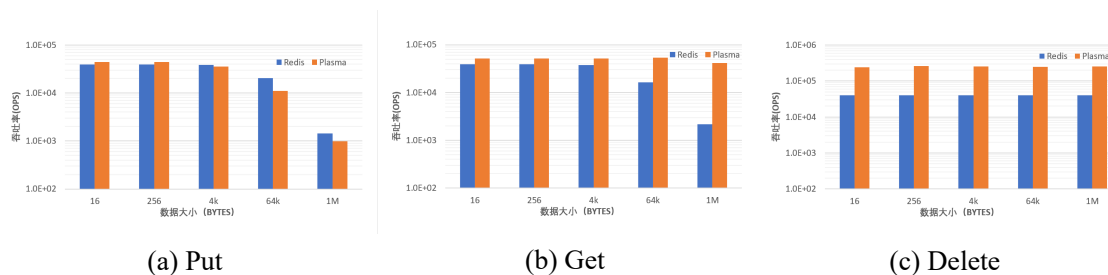


图 2.5 Redis 和 Plasma 常见操作吞吐对比

如图 2.5 所示，Plasma 单机存储架构的综合性能优于 Redis。Plasma 和 Redis 的“put”操作并不相同：对于前者，这一语义实际上是用户通过调用创建（Create）操作一段分配内存空间，然后将数据对象拷贝到该空间，最终释放（Release）并封装（Seal）对象。可以看到，由于复杂的处理过程，Plasma 在这一操作上有稍高的延迟。由于 Plasma 通过 MMAP 机制，在读取操作上支持了零拷贝特性，用户仅需通过 IPC 接收固定大小的文件描述符，因而在任何数据大小上都具有相似的性能。相反，Redis 使用 IPC 传输实际数据给用户进程。因此随着数据量增大到 1M，

Plasma 将对 Redis 有 20 倍的性能优势。Plasma 和 Redis 在删除上均拥有常数时间复杂度。

2.4.2 数据传输测试

进一步，我们在两个高性能节点上测试了 Plasma 和 Redis 在跨节点数据传输上的吞吐能力。对于 Redis，我们在远端节点启动 Redis 服务器，然后在本地基准测试中重复调用 Get 操作进行测试。对于 Plasma，在远端节点创建多个数据对象，然后在本地节点调用拉取 (Fetch) 操作。




图 2.6 Redis 和 Plasma 数据传输吞吐对比

如图 2.6 所示，Plasma 在远程操作上的吞吐能力比较显著地劣于 Redis，在 1M 大小数据上前者有 3.6 倍的传输延迟。虽然，两者实际完成的语义很不相同——Plasma 需要先获取对象在集群中的位置，这本身就将访问一次 Redis 服务器。另外，Plasma 发起一次拉取操作包含了一次本地 Create 操作，也将产生额外的延迟。而且，Plasma 一次仅以 4kb 为单位传输数据，也是大数据上传性能明显不如 Redis 的原因。然而，从我们的实验结果总结来看，不论是 Redis 还是 Plasma 都存在明显的性能提升空间：它们均不能很好地利用超算网络的低延迟和高带宽。特别是支撑分布式计算框架的 Plasma，在较大数据的传输上具有明显的性能劣势，这是原实现没有解决的问题。因此，这一观察促使我们基于超算网络对 Plasma 的数据传输机制进行针对性优化。

3 基于 RDMA 的 Plasma 数据传输机制实现

在本章节中，我们将基于上一章对 Plasma 架构和性能的分析，提出并实现一种适应各大小数据的高吞吐数据传输机制。由于跨节点通信完全由 Manager 进程完成，因此在本章节中，如无特殊说明，进程均指的是 Manager 进程。

3.1 连接的建立和复用

要进行双边 (Send/Recv) 和单边 (Read/Write) 通信，通信两端都需要首先为建立 Infiniband 连接。和套接字简单的连接过程不同，在双方能够通过发送事务传送数据之前，首先要完成如下准备工作：

- 1) 创建 IB 上下文 (Context)；得到机器的 IB 设备列表，并打开其中一个设备 (网卡)。用户可以在此时读取网卡的部分硬件参数。
- 2) 创建一个保护域 (Protection Domain, PD)。这是一种管理机制，后续创建的数据结构只有处在同一个保护域中才能相互访问。
- 3) 创建发送/接收缓冲区，并将其注册为内存区域 (Memory Region, MR)。这一操作的主要目的是使内存页面驻留在物理内存中，防止操作系统通过换页等机制将内存空间移出。由于 RDMA 实现在用户态，缓冲区的检查和数据收发都需要由用户正确地管理——否则会导致旧数据被覆盖等错误。
- 4) 创建完成队列 (Completion Queue, CQ)。在双边通信中，用户通过拉取完成队列来检查通信事务的执行结果。
- 5) 双方进程创建并连接队列对 (Queue Pair, QP)。使用可靠连接 (RC) 服务时，一对队列对在建立连接后只能相互发送数据。要建立一对连接，用户需要使用套接字等基础通信手段交换队列对的关键参数：网卡设备的本地编号 (lid) 和队列对编号 (qp_num)。

IB 连接的建立流程有显著的时间开销。在实验中，我们通过测试发现这一流程将引入额外 300ms 左右的延迟开销。这一结果和^[1]的描述基本一致。尽管由于面向单机，这一开销在高并发内存系统的相关研究中并没有得到很大重视，然而这对于分布式内存系统 Plasma 来说是重要的。后者在每个节点都要部署进程，其 IB 连接以 $O(N^2)$ 速度扩大规模。加之 Plasma 具有不规律的通信特征，即便是基于套接字的实现，大量并发的连接请求也造成了显著的性能损失。因此在集群中反复建立 IB 连接更是难以忍受的。

所以，我们必须在节点间复用 IB 连接。值得注意的是，步骤 3 创建并固定内存缓冲区占用了上述过程的主要时间开销，并且这一过程不依赖于队列对的连接。所以，在 IB 优化的 Plasma 实现中，我们先尝试建立队列对，然后才分配缓冲区。我们为每个进程维护了一个以网卡编号 lid 为键的哈希表。哈希表中的每个元素，以一个数据结构保存着一对 IB 连接的必要数据。因此，当两个进程尝试建立连接时，它们将首先通过套接字交换 lid，并查找哈希表。如果两个节点曾经建立过 IB 连接，那么双方将复用第一次分配好的缓冲区。通过这一改进，Plasma 仅有初次 IB 连接会感受到明显的传输延迟，而重复连接的时间开销大幅降低。

3.2 基于双边通信的传输协议

针对内存数据库常见的较小数据，我们提出了基于双边通信机制的传输协议。这一机制的优势在于，能够充分利用两节点间预先分配的发送/接收缓冲区。其示意图如图 3.1 所示：




图 3.1 基于双边通信的传输协议

在该传输协议中，通信双方（Sender/Receiver）在握手发生前必须首先通过一次 post_rcv 操作将一个接收事务放入到接收队列中。这是因为任何一个发送事务在完成时，连接的接收队列必须有可用的接收事务对应，否则通信无法发生。在本实现中，由于每个进程都维护着与其他进程的 IB 连接和对应的缓冲区，因此做法是在连接建立时，进程都首先将一个接收事务放入到和该连接关联的接收队列中。

这样我们就能确保第一次数据传输的握手发生前，接收队列总是存在可用的接收事务。

当数据发送方收到类型为 `PLASMA_TRANSFER` 的消息后，和套接字协议一样，它首先调用 `plasma_get` 函数得到了数据缓冲区的地址。然后，发送方将对象 `id`、数据大小等关键元数据通过 `PLASMA_DATA` 消息传递给数据接收方。之后，发送方将数据从得到的内存拷贝到预留的发送缓冲区，调用 `post_send` 将数据通过 RDMA 发送到接收方预留的接收缓冲区。值得注意的是：

- 1) 以此协议发送和接收数据，发送方和接收方在这一阶段都会产生一次用户态的内存拷贝。如图 3.1 中虚线箭头所示：为了复用预先分配的内存缓冲区、避免重复的内存分配和注册，发送前数据必须要拷贝到固定缓冲区，接收时必须要从固定缓冲区拷贝。在较小数据的传输中，这两次内存拷贝的开销占比较低，因而是较优的通信方案。
- 2) RDMA 传输的数据和接收方调用 `plasma_create` 的顺序是不定的，但不影响该协议的正确性，图 3.1 展示了其中一种顺序。数据可能先于元数据到达，也可能后于元数据到达。但不论事件以何种顺序发生，接收方都会在元数据到达后，调用 `plasma_create` 创建对象，然后轮询完成队列（CQ），确保对象数据已经到达。最后通过一次用户态的内存拷贝，将数据存到指定位置。在这里，轮询完成队列充当了同步的角色——如果数据已经到达，它将立刻返回；否则将阻塞，直到数据在缓冲区准备就绪。这一现象展示了 RDMA 通信的异步性。

接受事务的补充：数据到达后，由于接收事务被消耗了，接收方在取出数据、确认缓冲区可覆盖之后，需要重新提交一个接受事务等待下次使用。在这一步，我们希望从完成队列里面获取接收数据的内存地址，以便将一个指向相同地址的接收事务补充到接收队列中。这一目的可以通过事务编号（Work Request ID）完成：IB 的事务编号是一个 64 位无符号整数，因此我们可以直接将接收地址作为事务的编号——这样还很方便地解决了事务编号的唯一性。

发送确认信息：和基于套接字的协议不同，此时接收方还需要发送一个确认（ACK）消息给发送方。因为发送方并不知道接收方何时重新准备好了接收事务和缓冲区（而这在套接字编程中是无需担心的），这一 ACK 消息用于启动下一轮的数据发送。如果没有这一确认消息，发送方可能会在接收方没有配对的接收事务时再次发送，进而导致程序错误。

3.3 基于单边通信的传输协议

双边协议的局限性：在实现了上述基于双边通信的传输协议后，在实验中我们已经观察到了相当的吞吐提升——即便完成传输所需的通信次数相比套接字协议更多，但 RDMA 通信的延迟极低。然而，进一步对程序在较大数据的传输测试中进行性能采集，我们发现当数据规模增加时，程序将大量 CPU 时间用于用户态的数据拷贝（即 `memcpy` 调用）。虽然，用户态的内存拷贝性能很高，在数据较小时导致的额外延迟并不显著，但随着数据增长到 1M 大小，CPU 的处理能力无法跟上 RDMA 网卡的吞吐能力，成为了性能瓶颈。

对于上述双边通信的传输协议，选择用数据拷贝代替反复创建/销毁缓冲区是出于对后者较大开销的忌惮。这一前提在大型数据下是否还成立呢？结论是否定的，在第四章的实验和分析中，我们确认了内存空间分配 + 注册具有更好的扩展性：在数据较大时，反而是 CPU 直接复制同样大小的数据更耗费时间。这一观察驱使我们进一步为较大数据单独设计一个支持零拷贝的传输协议。我们实现了基于单边读（One-sided Read）的约会（Rendezvous）协议，其示意图如图 3.2 所示：

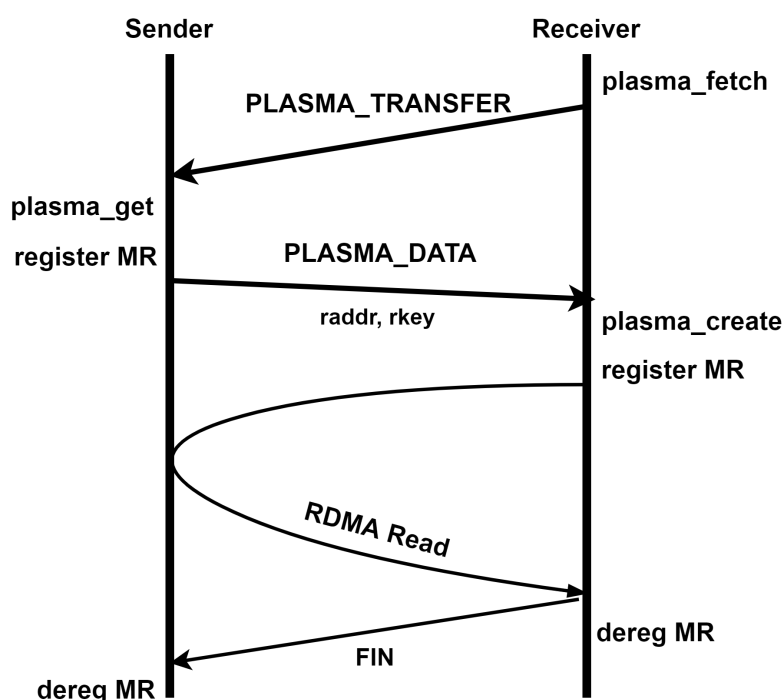


图 3.2 基于单边通信的传输协议

在基于单边读的传输协议中，使用了与传统通信原语极为不同的读语义：发送方不再事实上承担发送数据的任务，而是由接收方直接从远端内存拉取数据到本地。在接受到 `PLASMA_TRANSFER` 消息，且通过 `plasma_get` 函数调用获得了数据对象的地址后，发送方直接向 RDMA 网卡注册 MMAP 映射返回的内存空间。

因此，内存数据将在原地被网卡读取并发送，而不再依靠预先分配的固定缓冲区。接下来，接收方将会收到发送方传递的元数据、创建内存空间，并同样向 RDMA 网卡注册 `plasma_create` 返回的内存地址。需要注意的是，这一阶段发送方需要额外地将本地内存地址 (`raddr, rkey`) 发送到接收方处，才能正确地引导后者拉取内存数据。此时，双方的内存空间都已原地 (`in-place`) 成为可用的发送/接收缓冲区，接收方发出一个单边读请求，就能完成对象的复制。最后，接收方通过一个结束 (`FIN`) 消息通知对方注销缓冲区，也同时注销自己的缓冲区。一次数据传输就完成了。

单边协议的技术优势：在这一协议中，我们将内存数据所处空间原地注册为缓冲区，这一协议具有一些优势：传输仅需要两个来回（一次握手和一次传输），相比之下双边协议的来回数依赖于固定缓冲区的大小；实现比前者更简单；为发送方和接收方各节省了一次用户态的数据拷贝，实验表明这一特性在数据较大时具有明显性能优势。

3.4 混合传输机制实现

上述的两种传输协议具有不同的性能表现，本质上是在两种固定开销中进行权衡：双边传输协议使双方增加了一次内存拷贝，避免了重复的内存注册/注销操作；单边传输协议每次传输都需要注册/注销内存，但真正实现了（用户态/内核态）内存零拷贝。直观上来说，前者适合发送小数据，而大型数据则应该采用后者传输。幸运的是，通过确定一个分界点，我们能将两种机制混合实现，而只需要对 Plasma 主逻辑做出微小改动。定义常量 `IB_READ_MIN_SIZE` 为采用单边协议的最小数据量，就能在函数调用前确定使用的协议。下面伪代码展示了发送端和接收端的处理逻辑：

算法 3.1: 服务端发送机制

输入： 连接上下文 `conn`，对象标识符 `id`

- 1 `buf`: 缓冲区, S_d : 数据大小, S_m : 元数据大小
- 2 读取对象内存区域: $buf, S_d, S_m \leftarrow \text{plasma_get}(id)$
- 3 发送元数据: $\text{send_message}(conn, S_d, S_m, id)$
- 4 **如果** $S_d + S_m \leq \text{IB_READ_MIN_SIZE}$ **则**
- 5 发送本地地址: $\text{ib_send_read_info}(conn, buf)$
- 6 等待单边读: $\text{ib_wait_object}(conn, buf)$
- 7 **否则**
- 8 双边发送协议: $\text{ib_send_object_chunk}(conn, buf)$
- 9 释放对象: $\text{plasma_release}(id)$

算法 3.2: 客户端接收机制

输入: 连接上下文 $conn$

- 1 buf : 缓冲区, S_d : 数据, S_m : 元数据大小, id : 对象标识符
- 2 接收元数据: $S_d, S_m, id \leftarrow \text{recv_message}(conn)$
- 3 创建对象内存区域: $buf \leftarrow \text{plasma_create}(id, S_d, S_m)$
- 4 **如果** $S_d + S_m \leq IB_READ_MIN_SIZE$ **则**
- 5 $raddr$: 远端内存地址
- 6 接收远程地址: $raddr \leftarrow \text{ib_recv_read_info}(conn)$
- 7 单边读协议: $\text{ib_read_object}(conn, buf, raddr)$
- 8 **否则**
- 9 双边接收协议: $\text{ib_recv_object_chunk}(conn, buf)$
- 10 确认对象: $\text{plasma_seal}(id)$
- 11 释放对象: $\text{plasma_release}(id)$

在之后的实验中, 我们将对套接字协议、双边传输协议和单边传输协议分别进行详细的性能测试, 确定出最优的参数, 从而得到最优的总体内存传输性能。

4 性能测试与结果分析

5 总结与展望

参考文献

附录 A 补充更多细节

A.1 补充图

A.1.1 补充图

这是附录内容，应该用宋体小四号字体。




图 A.1 一个配有彩色表格的插图

致谢

四年时间转眼即逝，青涩而美好的本科生活快告一段落了。回首这段时间，我不仅学习到了很多知识和技能，而且提高了分析和解决问题的能力与养成了一定的科学素养。虽然走过了一些弯路，但更加坚定我后来选择学术研究的道路，实在是获益良多。这一切与老师的教诲和同学们的帮助是分不开的，在此对他们表达诚挚的谢意。

首先要感谢的是我的指导老师王大明教授。我作为一名本科生，缺少学术研究经验，不能很好地弄清所研究问题的重点、难点和热点，也很难分析自己的工作所能够达到的层次。王老师对整个研究领域有很好的理解，以其渊博的知识和敏锐的洞察力给了我非常有帮助的方向性指导。他严谨的治学态度与辛勤的工作方式也是我学习的榜样，在此向王老师致以崇高的敬意和衷心的感谢。

最后我要感谢我的家人，正是他们的无私的奉献和支持，我才有了不断拼搏的信心和勇气，才能取得现在的成果。

王小明

2022 年 4 月 1 日